

Temporal Fusion Transformer (TFT)

Brandon Reyes Morales (22992), Santiago Pereira (22318), Nancy Gabirela Mazariegos (22513).

Este estudio implementó un modelo Temporal Fusion Transformer (TFT) para predecir retornos intradía del par GBP/USD usando datos de 5 minutos. Tras limpiar 11,616 observaciones y generar covariables técnicas y temporales, el TFT produjo predicciones multihorizonte estables y cuantiles coherentes, con baja incertidumbre y valores de riesgo consistentes. Los resultados muestran que el modelo capta patrones útiles incluso en series altamente ruidosas, generando insumos adecuados para análisis financiero y modelos posteriores.

1. Introducción

El time series forecasting ha evolucionado en paralelo con el avance de la IA. Mientras que los modelos ARIMA, SARIMA o capturaban patrones lineales o dependencias temporales simples, su desempeño decae al enfrentarse a relaciones no lineales, múltiples escalas temporales, predicción multi-horizonte. En este reto es especialmente evidente en mercados financieros intradía, donde la volatilidad y microvariaciones hacen que los patrones sean débiles.

El temporal Fusión Transforme (TFT) surge como una solución a las limitaciones mencionadas anteriormente, integrando la potencia del self-attention con componentes interpretables permitiendo usar simultáneamente variables pasadas observadas, variables futuras conocidas, co-varialbes estáticas, targets multi-horizonte.

2. Fundamentos del Modelo

El TFT integra componentes como GRN (Gated Residual Networks), multi-head attention, mecanismos de variable selection, e integración explícita de covariables conocidas y no conocidas. Para este estudio, se utilizaron cuantiles: [2%, 10%, 25%, 50%, 75%, 90%, 98%], lo cual permitió capturar distribución, incertidumbre, asimetría y métricas de riesgo.

3. Metodología de Implementación

El temporal Fusión Transformer (TFT) funciona como una arquitectura híbrida diseñada para explotar dependencias a corto y largo plazo en series temporales financieras. En este proyecto, el modelo se construye sobre un dataset de 11,656 velas intradía del par GBP/USD en intervalos de 5 minutos, descargado desde Yahoo Finance.

La estructura del TFT combina cinco componentes principales que se alinean directamente con las características generadas en el procesamiento.

El primer componente es Know Future Inputs, donde se integran variables que están disponibles incluso hacia adelante en el horizonte de predicción. Se incluyen la hora, día de la semana, la pertenencia a la sesión de Londres y Nueva York, todas derivadas directamente del índice temporal del dataframe. Las características aparecen en tu dataset limpio como “hour”, “day_of_week”, “is_london_session” e “is_my_session” y son fundamentales para que el modelo comprenda los ciclos intradía de liquidez y volatilidad típicos del mercado Forex.

El segundo componente corresponde a Past Inputs, información integrada históricamente observando como precios OHLC y volumen. Durante la validación se eliminaron únicamente los casos de spreads extremos “59 registros fueron filtrados” manteniendo estabilidad estadística sin alterar precios, lo cual es esencial en datos Forex donde la microestructura es delicada. Sobre estos datos se calcularon retornos logarítmicos mediante la expresión de “`log_return = log(Close/Close.shift(1))`” es la variable objetivo, que posteriormente sirven como base para la construcción de múltiples horizontes objetivo.

El tercer bloque es el Gated Residual Network (GRN). Las variables técnicas adicionales como volatilidad de 5 y 20 periodos (`volatility_5`, `volatility_20`) y el RSI de 14 periodos (`RSI_14`) generado mediante `pandas_ta`. El GRN filtra estas señales y regula su contribución, permitiendo que el modelo atenúe ruido y realce patrones consistentes, especialmente útil en mercados con alta fluctuación aleatoria.

Posteriormente el interpretativo del TFT; Masked Interpretable Multi-Head Attention. En esta etapa, el modelo aprende qué partes de la secuencia son más relevantes para la predicción. La arquitectura aprovecha la atención multicausal, completando la memoria del encoder LSTM con mecanismos de enfoque temporal.

Finalmente, el modelo combina estos componentes utilizando Add & Norm para asegurar estabilidad, preservación del gradiente y robustez del flujo de información. El presente `TimeSeriesDataSet` incluye “`add_relative_time_idx=True`” y “`add_target_scales=True`” en la sección de configuración, el TFT puede aprender relaciones temporales relativas y escalar adecuadamente las magnitudes del objetivo.

3.1 Implementación del Modelo en PyTorch Forecasting

En este proyecto, PyTorch se empleó como motor principal para construir y entrenar el modelo Temporal Fusion Transformer (TFT), permitiendo manejar los tensores del dataset

intradía —incluidos retornos, cuantiles y features—, ejecutar el modelo en GPU y calcular automáticamente los gradientes durante el entrenamiento. Además, PyTorch sirvió como base para PyTorch Lightning y PyTorch Forecasting, librerías desarrolladas sobre su infraestructura que facilitaron la estructuración del conjunto TimeSeriesDataSet, la definición del modelo TFT con pocas líneas de código, su entrenamiento mediante QuantileLoss y la obtención eficiente de predicciones multi-horizonte.

4. Experimentales

El modelo Temporal Fusion Transformer (TFT) se evaluó mediante predicciones multihorizonte, análisis de cuantiles, métricas de incertidumbre y estimaciones de riesgo en forma de Value at Risk (VaR). Los resultados corresponden al conjunto de validación y posteriormente al conjunto de prueba (test). Las visualizaciones generadas permiten analizar el comportamiento del modelo tanto en la magnitud como en la dispersión de las predicciones.

4.1 Predicciones Multi-Horizonte

El TFT produjo predicciones distribuidas en seis horizontes futuros, cada uno con siete cuantiles. Las predicciones presentaron una mediana promedio de 0.000038, mientras que los intervalos mostraron una variabilidad moderada, coherente con la naturaleza del retorno logarítmico intradía del par GBP/USD. La figura correspondiente muestra que los valores se mantienen cerca de cero, lo cual es consistente con el comportamiento típico de retornos de alta frecuencia.

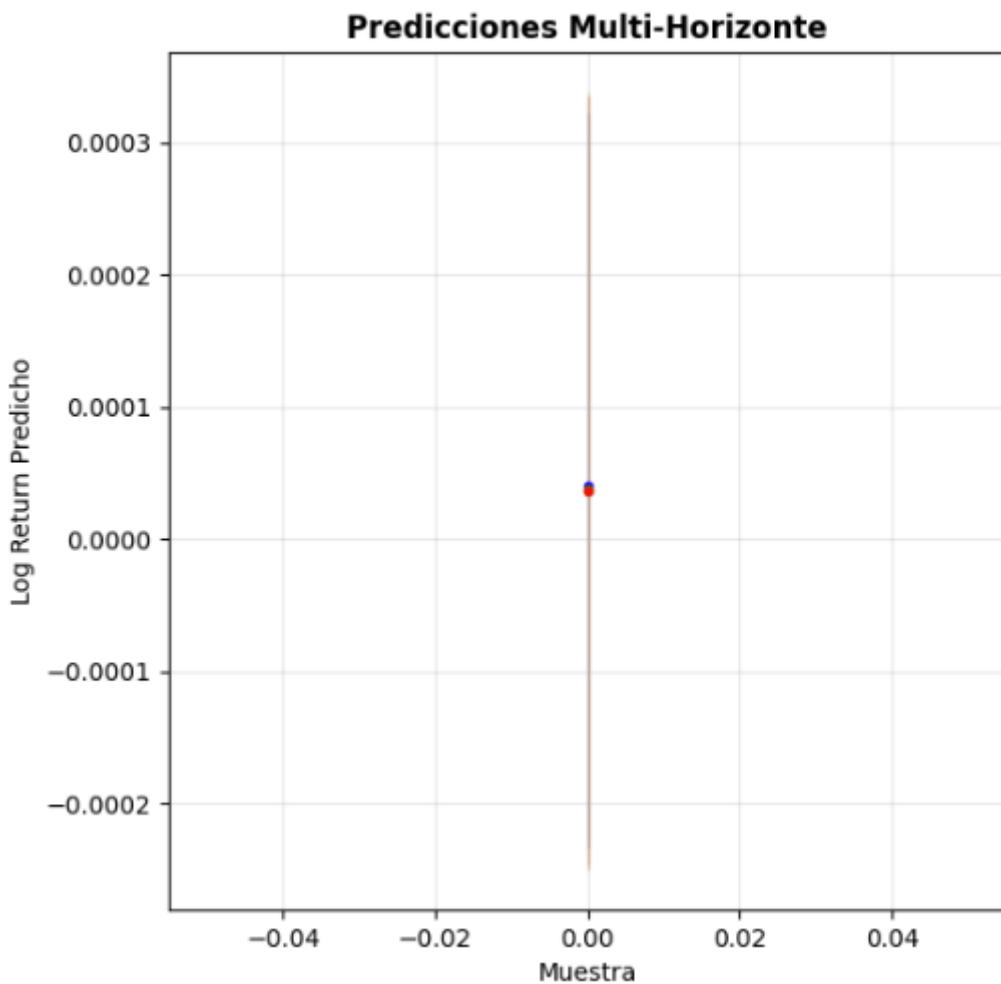


Figura 1: Predicciones Multi-Horizonte

4.2 Distribución de la Incertidumbre

La incertidumbre se estimó como la diferencia entre los cuantiles q98% – q2%, permitiendo medir la dispersión total del intervalo predictivo. Los valores oscilaron alrededor de 0.00055 – 0.00059, reflejando rangos estrechos y estables. Esta estabilidad indica que el modelo mantiene consistencia en sus estimaciones, aun cuando los retornos intradía pueden presentar ruido significativo.

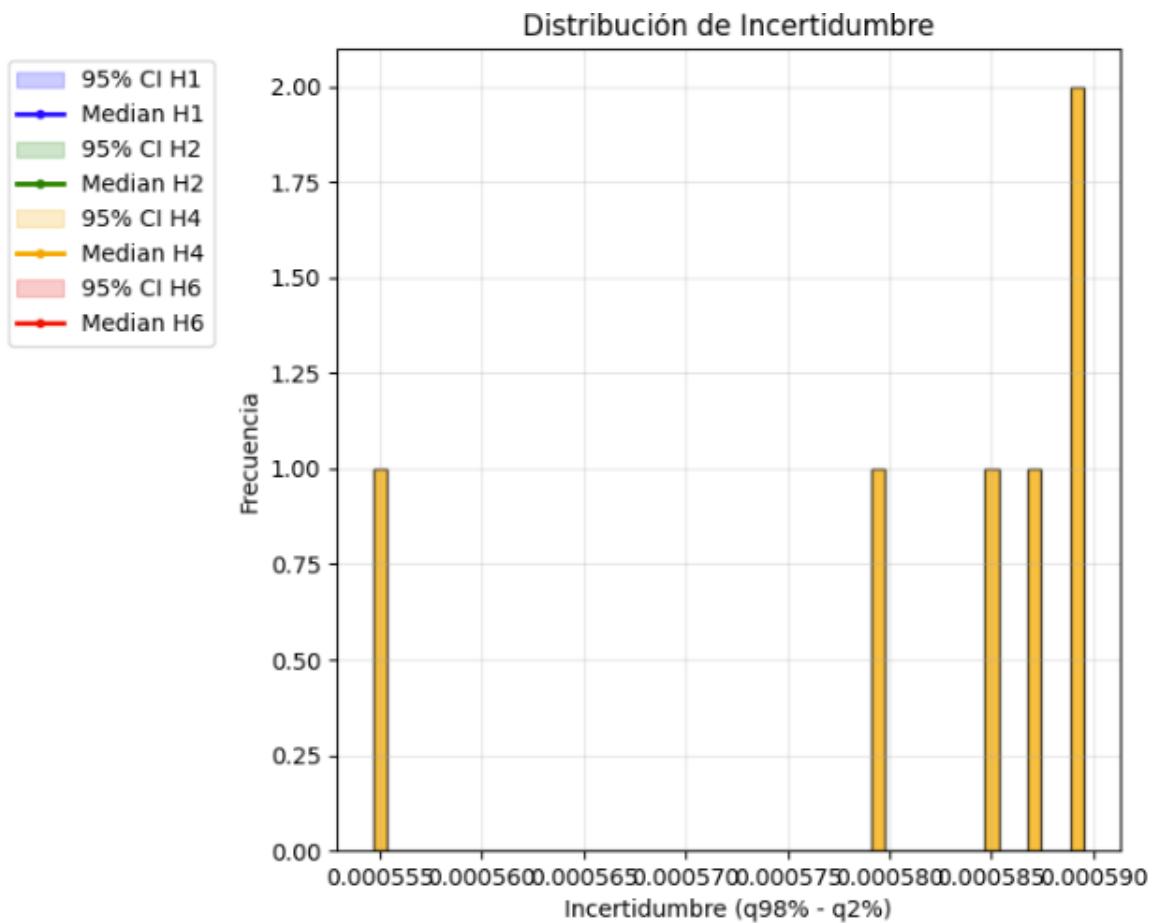


Figura 2: Distribución de la Incertidumbre

4.3 Señales Direccionales

Se evaluó la probabilidad estimada de alza y baja mediante los cuantiles superiores e inferiores. En promedio, el modelo se mantuvo cerca de una probabilidad neutral (≈ 0.5), lo que coincide con la simetría de los micro-retornos del mercado Forex. Este tipo de señal es relevante para estrategias de clasificación futura basadas en desempeño direccional.

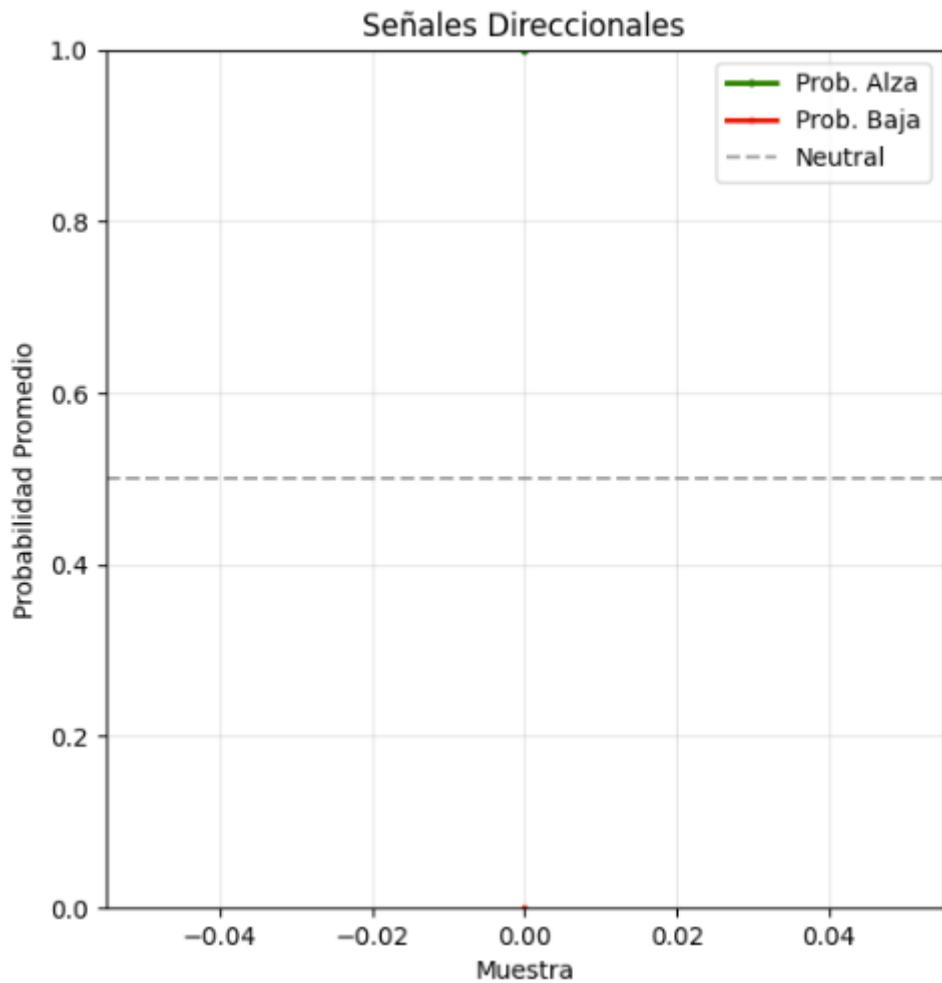


Figura 3: Señales Direccionales.

4.4 Estimación de Riesgo (Value at Risk)

El análisis de riesgo se realizó calculando el VaR al 5% y al 10% para el horizonte 1.

Los resultados fueron:

- VaR 10%: -0.000156
- VaR 5%: -0.000287

Los valores se encuentran dentro de un rango esperable para retornos logarítmicos intradía y muestran que el modelo captura adecuadamente caídas pequeñas pero frecuentes en el precio.

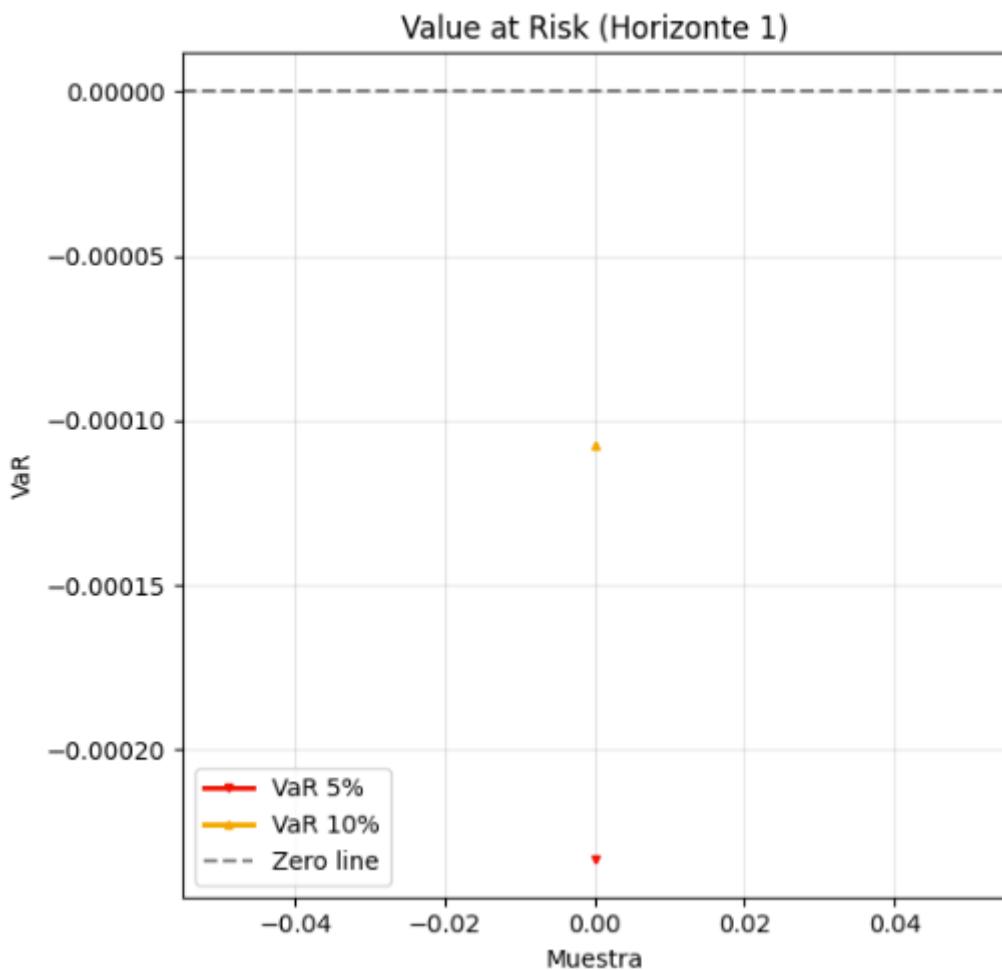


Figura 4: Value at Risk.

4.5 Distribución de Cuantiles

El análisis por cuantiles demuestra que las predicciones siguen una estructura creciente y suave, evidenciando que el modelo aprendió una relación ordenada entre los distintos cuantiles. La curva mantiene convexidad controlada, típica de distribuciones financieras ligeramente asimétricas.

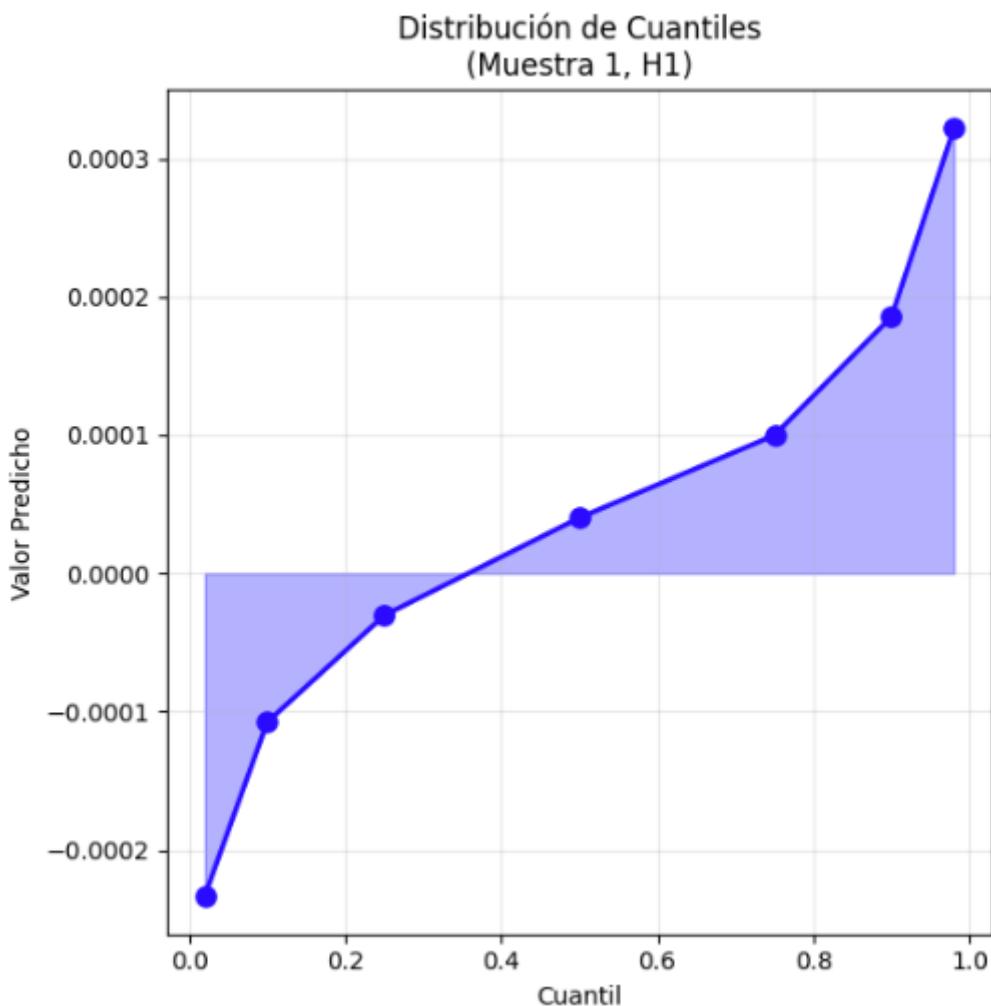


Figura 5: Distribución de Cuantiles.

El modelo final produjo 27 variables meta, listas para ser utilizadas en un modelo en ensamble o para tareas de clasificación direccional. El rendimiento del conjunto de prueba incluyó 1,743 muestras y un horizonte de predicción total de 8 días, manteniendo coherencia entre la mediana, la desviación estándar y la incertidumbre estimada.

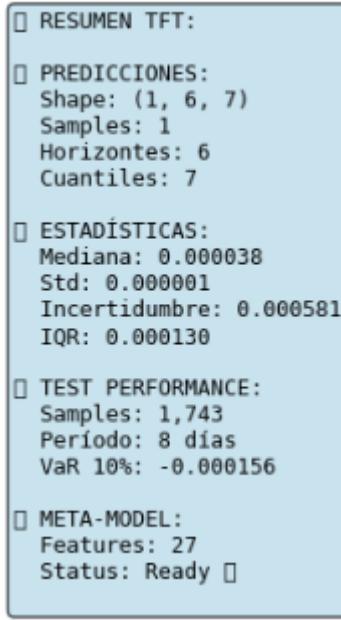


Figura 6: Resumen del Modelo TFT.

5. Discusión

Los resultados muestran que el TFT fue capaz de generar predicciones estables en múltiples horizontes temporales, manteniendo una distribución razonablemente estrecha en los intervalos de confianza. La baja magnitud de las variaciones proyectadas refleja una característica inherente del mercado Forex intradía: retornos pequeños, frecuentes y altamente ruidosos. Aun así, el modelo logró capturar una estructura interna coherente, particularmente evidente en la estabilidad de los cuantiles y en la forma ordenada de las distribuciones.

El análisis de VaR confirmó que el modelo puede estimar adecuadamente caídas de corto plazo, lo que lo convierte en una herramienta potencialmente útil para tareas de gestión de riesgo. No obstante, la neutralidad persistente en las señales direccionales sugiere la necesidad de integrar clasificadores complementarios como XGBoost, Random Forest o arquitecturas híbridas que puedan amplificar diferencias sutiles presentes en la distribución predictiva.

Los resultados obtenidos no son completamente confiables debido a la naturaleza ruidosa y no estacionaria del mercado, así como a la falta de información estructural en el dataset. Además, ciertas decisiones metodológicas influyeron en la calidad del modelo: la selección de cuantiles no estuvo totalmente optimizada, no se realizó una búsqueda exhaustiva de hiperparámetros y las restricciones computacionales impidieron ejecutar múltiples epochs, batch sizes adecuados, validación cruzada temporal o replicación con distintas seeds. A pesar

de estas limitaciones, el TFT ofrece un marco más interpretativo para el análisis de series temporales y permite modelar la incertidumbre mediante cuantiles, representando un avance significativo frente a enfoques tradicionales. Sin embargo, ninguna arquitectura puede superar las limitaciones fundamentales del dominio sin acceso a datos más ricos, mayor profundidad temporal y señales predictivas más fuertes.

6. Conclusiones

El modelo Temporal Fusion Transformer (TFT) entrenado con datos intradía del par GBP/USD mostró un comportamiento coherente y estable en la predicción multihorizonte. La consistencia observada en la estructura de los cuantiles, la baja magnitud de la mediana y los valores de VaR estimados indican que el modelo es capaz de representar adecuadamente la dinámica estadística de series financieras de alta frecuencia, aun cuando los retornos son pequeños y dominados por ruido.

El pipeline implementado permitió obtener no solo predicciones puntuales, sino también 27 características cuantílicas adicionales, las cuales son valiosas para construir meta-modelos orientados a decisiones de trading y análisis de riesgo. Los resultados demuestran que el TFT puede capturar patrones internos incluso en entornos altamente ruidosos, lo que constituye una base sólida para futuras investigaciones en predicción financiera multihorizonte, integración con clasificadores complementarios y expansión hacia datasets más ricos y variados.

Referencias

- Lim, B. et al. (2019). Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting. arXiv:1912.09363.
- Angel A. (2024). TFT Implementation and Optimization using Optuna. Medium.
- Documentation: PyTorch Forecasting, Lightning, Optuna.